

校园 qwen3.8-27b · Harness 接入指南

华北电力大学 AI 编程大模型 —— 接入各类编码 Agent / CLI / 客户端的完整配置手册

网页端入口 · 202.204.64.234:8080 <http://202.204.64.234:8080>

学校官方教程 · lab.ncepu.edu.cn <https://lab.ncepu.edu.cn/bslc/rjzy/0b468cf674694cf6b9feaf95883a7352.htm>

整理日期 2026-09-24

8 项能力实测通过

vLLM 0.29.1.dev1

TP=4

256K 上下文

免费 (校内)

1 先搞清楚这件事：harness 分两类

这是整份指南最重要的一节。学校端点很特殊 —— 只有一条路径能用：

✓

`http://202.204.64.234:8080/api/chat/completions`

✗

`http://202.204.64.234:8080/api/v1/chat/completions`

→ 405

✗

`http://202.204.64.234:8080/api//chat/completions`

→ 405 (尾斜杠导致)

✗

`http://202.204.64.234:8080/v1/chat/completions`

→ 405

而不同 harness 拿到你填的 Base URL 后，自己拼接的路径不一样：

类型	拼接行为	填 ... /api 的结果	代表工具
A 类	只拼 <code>/chat/completions</code>	✓ 正确	OpenAI Python/Node SDK、Continue、Dify、WorkBuddy (自定义协议关闭)、curl
B 类	强制拼 <code>/v1/chat/completions</code>	✗ 405	多数桌面客户端、部分版本的 Cline / Roo Code、Aider

怎么判断你的工具属于哪类

1. 直接试：Base URL 填 `http://202.204.64.234:8080/api`，发一条消息。
 - 正常回复 → A 类，收工
 - 报 405 / 404 → B 类，往下看
2. B 类的解法 (二选一)：
 - 找工具里有没有「自定义完整路径」「Use custom path」之类的选项
 - 直接用第 5 节的本机反代 (推荐，一次配好所有工具都能用)

2 获取 API Key (官方入口)

官方文档说明：网页、客户端、Cline 插件、API 调用四种方式使用前均需在学校网站注册用户，其中后三种还需创建 API 密钥。

入口	地址	用途
Open WebUI 网页端	http://202.204.64.234:8080	注册账号 / 登录 / 创建 API 密钥 / 直接对话
学校官方教程	lab.ncepu.edu.cn → 《AI编程大模型上线》	原始文档 (含注册、密钥创建、客户端配置截图)

创建 API 密钥（官方步骤）

- 1 浏览器打开 <http://202.204.64.234:8080>，注册账号并登录
- 2 点击右上角圆形头像图标
- 3 选择「设置」
- 4 选择「账号」
- 5 点击「API 密钥」
- 6 点击「创建新安全密钥」
- 7 点击「保存」，复制生成的 `sk-` 开头的密钥

拿到密钥后放哪里

本包的自检脚本与本地反代都从同目录 `api_key.txt` 读取 —— 把密钥粘到第 1 行即可。也可以启动反代时用 `--key sk-xxx`，或设环境变量 `NCEPU_API_KEY`。

官方文档的三处错误（实测勘误）

文档发布于 2025-11-21，部分内容已过时，照抄会踩坑：

#	文档写的	实际情况
1	模型名 <code>qwen3-coder:30b</code> （客户端那节又写成 <code>qwen3-code:30b</code> ）	已换成 <code>qwen3.8-27b</code> ，服务器上只有这一个模型。照文档填会报模型不存在
2	Cline 那节 Base URL 写 <code>http://202.204.64.234:8080/api/</code> （带尾斜杠）	会拼成 <code>/api//chat/completions</code> → 405。应去掉尾斜杠
3	Cline 那节超链接损坏，显示成 <code>http://202.204.64.234:11434%EF%BC%8CModel/</code>	链接本身失效，忽略即可

文档第 4 节的 API 调用示例里，URL 是对的（`http://202.204.64.234:8080/api/chat/completions`），只有 `model` 字段需要改成 `qwen3.8-27b`。

文档推荐的客户端（Cherry Studio / ChatWise）

官方教程给了 Cherry Studio 的配置示例，注意两处要改：

字段	文档写的	应该填
模型服务	OpenRouter	OpenRouter（照填即可 —— 它只是借这个通道走自定义地址）
API 地址	<code>http://202.204.64.234:8080/api/</code>	<code>http://202.204.64.234:8080/api</code> （去掉尾斜杠）
模型	<code>qwen3-code:30b</code>	<code>qwen3.8-27b</code>

3 通用参数（所有 harness 共用）

Base URL（直连）	<code>http://202.204.64.234:8080/api</code>
Base URL（走反代）	<code>http://127.0.0.1:8788/v1</code>
Model ID	<code>qwen3.8-27b</code>

API Key	sk- 开头，35 位 —— 获取方法见 第 2 节（网页端 → 头像 → 设置 → 账号 → API 密钥 → 创建新安全密钥）
协议	OpenAI 兼容 → Chat Completions API（不是 Responses API）
上下文	256K（ max_model_len=262144 ，输入+输出合计）

三条铁律

- 1. Base URL 末尾不加斜杠 → 加了会变成 //chat/completions ， 405
- 2. 不加 /v1（除非走反代）→ /v1/ ... 一律 405
- 3. 模型名是 qwen3.8-27b ，不是学校文档写的 qwen3-coder:30b → 填错报模型不存在

服务端实况（本次实测新增）

项	值
推理引擎	vLLM 0.29.1.dev1（ system_fingerprint 字段暴露）
并行方式	TP=4（4 卡张量并行，说明学校至少部署了 4 张卡）
流式 delta	思考内容通过 delta.reasoning 逐块下发（做前端要注意解析这个字段）
视觉	图片输入可用， usage.prompt_tokens_details.multimodal_tokens 会记录图像 token 数

```
= 4. 列出可用模型 ==
[通过] 共 1 个模型
[信息]    qwen3.8-27b

警告] 模型列表里没有 qwen3-coder:30b，尝试匹配包含 'qwen' 的项。
[信息] 改用：qwen3.8-27b

= 5. 真实对话测试（model=qwen3.8-27b） ==
[通过] 调用成功，端到端耗时 3.74s
[信息] tokens: prompt=83 completion=323 total=406

---- 模型输出 ----
```python
import csv

def read_csv(file):
 [print(r) for i, r in enumerate(csv.reader(open(file))) if i < 5]
```

-----
Press any key to continue
```

实测证据（自检脚本第 4-5 步输出）：模型列表里只有 qwen3.8-27b 一个模型，脚本按学校文档找 qwen3-coder:30b 直接落空 —— 文档确实过时了。下方真实对话测试端到端 3.74s，prompt 83 + completion 323 = 406 tokens。

4 逐 harness 配置

4.1 已验证可用

OpenAI Python SDK A 类 · 直接可用

```
from openai import OpenAI

client = OpenAI(
    base_url="http://202.204.64.234:8080/api", # 注意: 没有 /v1
    api_key="sk-你的密钥",
)

resp = client.chat.completions.create(
    model="qwen3.8-27b",
    messages=[{"role": "user", "content": "你好"}],
    max_tokens=512,
)

print(resp.choices[0].message.content)
print(resp.choices[0].message.reasoning) # 思考内容在这里, 不是 reasoning_content
```

curl A 类

```
curl http://202.204.64.234:8080/api/chat/completions \
-H "Content-Type: application/json" \
-H "Authorization: Bearer sk-你的密钥" \
-d '{"model": "qwen3.8-27b", "messages": [{"role": "user", "content": "你好"}]}'
```

Qoder / WorkBuddy A 类

详细步骤见 `接入参数.md`。WorkBuddy 的「添加模型」弹窗按下面这张图勾选:

添加模型

×

模型名称

qwen3.8-27b

高级配置

☒ 工具调用

☒ 图片输入

☒ 思考模式

☐ 仅思考模式

☒ 允许关闭思考

☐ 自定义协议

当前只会展示思考开关，不会展示强度选择；如果该模型支持强度调节，请在下方选择可用档位。

默认思考强度

自动（使用请求层默认值）

支持的思考强度

☐ 低

☐ 中

☐ 高

☐ 超高

☐ 极致

输入

使用提供商默认值

32K64K128K256K

输出

使用提供商默认值

8K16K32K64K

取消

保存

WorkBuddy「添加模型」弹窗：模型名称必须逐字符填 `qwen3.8-27b`（这是发给 API 的 Model ID，不是随便起的显示名）；「自定义协议」**保持关闭**，关闭时才会自动补 `/chat/completions`；「支持的思考强度」五档里**只勾低/中/超高**。

| 界面项 | 填 / 勾 | 依据 |
|---------|---------------------------------------|--|
| 模型名称 | qwen3.8-27b | 发给 API 的 Model ID，必须逐字符一致 |
| 工具调用 | ☒ 勾 | 实测正确返回 <code>tool_calls</code> ，不勾则 Agent 能力失效 |
| 图片输入 | ☒ 勾 | 实测纯色图 2/2 答对 |
| 思考模式 | ☒ 勾 | 实测默认返回 <code>reasoning</code> 字段 |
| 仅思考模式 | ☐ 不勾 | 实测可关闭思考，不是「只能思考」的模型 |
| 允许关闭思考 | ☒ 勾 | <code>enable_thinking=false</code> 实测生效 |
| 自定义协议 | ☐ 不勾 | 不勾才会自动补 <code>/chat/completions</code> ；勾了反而拼错 |
| 默认思考强度 | 自动 | 使用请求层默认值 |
| 支持的思考强度 | 只勾 低 / 中 / 超高 | ⚠ 勾「高」「极致」运行时 会 400 |
| 输入 / 输出 | 128K / 32K | 两者合计不得超过 262144 |

4.2 IDE 插件

Cline（VSCode 扩展）

| 字段 | 填 |
|--------------|---|
| API Provider | OpenAI Compatible |
| Base URL | http://127.0.0.1:8788/v1（走反代最稳）；若坚持直连填 http://202.204.64.234:8080/api |

| 字段 | 填 |
|-----------------|---|
| API Key | sk- ... |
| Model ID | qwen3.8-27b |
| Context Window | 手动填 131072 （别用默认值，会浪费上下文或超限） |
| Supports Images | ☒ 勾（实测视觉可用） |

学校官方文档的坑

文档那节写的是 `http://202.204.64.234:8080/api/`（带尾斜杠），实测会拼成 `/api//chat/completions` → 405。照抄文档会踩坑，改成不带斜杠的。

Roo Code (VSCode 扩展)

配置项与 Cline 完全一致（API Provider 同样选 `OpenAI Compatible`）：Base URL `http://127.0.0.1:8788/v1`、Model `qwen3.8-27b`、勾选图片支持。

Continue.dev

```
~/ .continue/config.yaml :

models:
  - name: NCEPU Qwen3.8-27B
    provider: openai
    model: qwen3.8-27b
    apiBase: http://202.204.64.234:8080/api      # A 类拼法；若报 405 改成 http://127.0.0.1:8788/v1
    apiKey: sk-你的密钥
    contextLength: 131072
    roles:
      - chat
      - edit
      - apply
```

4.3 CLI 工具

Aider

```
export OPENAI_API_BASE=http://202.204.64.234:8080/api
export OPENAI_API_KEY=sk-你的密钥

aider --model openai/qwen3.8-27b
```

若报 405/404，把 `OPENAI_API_BASE` 改成 `http://127.0.0.1:8788/v1`（Aider 内部走 litellm，拼接策略随版本变动）。

Claude Code 等 Anthropic 协议工具

Claude Code 说的是 Anthropic Messages API（`/v1/messages`），不能直连 OpenAI 兼容端点，需要一个转换层。用 LiteLLM：

```
# litellm.yaml
model_list:
  - model_name: qwen3.8-27b
    litellm_params:
      model: openai/qwen3.8-27b
      api_base: http://202.204.64.234:8080/api
      api_key: os.environ/NCEPU_API_KEY
```

```
pip install "litellm[proxy]"
export NCEPU_API_KEY=sk-你的密钥
litellm --config litellm.yaml --port 4000

# 另开一个终端，让 Claude Code 指向本地转换层
export ANTHROPIC_BASE_URL=http://127.0.0.1:4000
export ANTHROPIC_AUTH_TOKEN=sk-1234
claude
```

此路径**未实测**（LiteLLM 转换层的 Anthropic 端点兼容性随版本变化）。另外 27B 模型跑 Claude Code 那种长链路 Agent 任务会比较吃力，建议先小任务试水。

4.4 桌面客户端

Cherry Studio / ChatWise / ChatBox / LobeChat / NextChat 等（前两个是学校官方文档推荐的）：

| 字段 | 填 |
|---------|--|
| 供应商 | OpenAI 或「自定义 OpenAI 兼容」 |
| API 地址 | 先试 <code>http://202.204.64.234:8080/api</code> ；报 405 就填 <code>http://127.0.0.1:8788/v1</code> |
| API Key | <code>sk- ...</code> |
| 模型名称 | <code>qwen3.8-27b</code> （手动添加，别指望自动拉列表） |

反代同时接受 `/v1/chat/completions` 和 `/chat/completions`，所以填 `http://127.0.0.1:8788/v1` 或 `http://127.0.0.1:8788` 都能命中，不用纠结。

4.5 平台类（Dify / n8n / FastGPT）

Dify

模型供应商 → OpenAI-API-compatible

| 字段 | 填 |
|--------------|---|
| API Base URL | <code>http://202.204.64.234:8080/api</code> |
| API Key | <code>sk- ...</code> |
| Model Name | <code>qwen3.8-27b</code> |
| Model Type | LLM |
| 功能开关 | Vision ☒ Function Calling ☒ Stream Function ☒ |

n8n

用 OpenAI Chat Model 节点 + 「OpenAI Compatible」凭据，Base URL 填 `http://127.0.0.1:8788/v1`（n8n 的凭据校验会调 `/models`，反代已提供该接口）。

FastGPT

OpenAI 兼容渠道，Base URL `http://202.204.64.234:8080/api`。

5

本地反代方案（解决所有 B 类 harness）

5.1 它做什么



顺带修掉三个已知的坑：

| 问题 | 反代的处理 |
|--|---|
| harness 传 reasoning_effort: high → 服务端 400 | 自动映射 high → xhigh （同理 max / ultra → xhigh , minimal → low ） |
| harness 传 max_tokens 过大 → 400 | 自动截断到 200000 |
| harness 传自己的模型显示名 | 强制改写成 qwen3.8-27b |

5.2 启动

```
# 方式一：双击 start-proxy.bat（推荐，会自动装依赖）

# 方式二：命令行手动启动
python ncepu_proxy.py

# 方式三：指定端口 / 直接传密钥
python ncepu_proxy.py --port 9000
python ncepu_proxy.py --key sk-你的密钥
```

密钥自动从同目录 api_key.txt 读取（也可用 --key sk-xxx 或环境变量 NCEPU_API_KEY ）。启动后终端会打印：

```
上游      : http://202.204.64.234:8080/api/chat/completions
模型       : qwen3.8-27b
监听       : http://127.0.0.1:8788
harness 里填：
  Base URL  : http://127.0.0.1:8788/v1
  API Key   : 任意值
  Model ID  : qwen3.8-27b
```

5.3 harness 侧填法

| | |
|----------|---|
| Base URL | http://127.0.0.1:8788/v1 （若工具又自动加 /v1 ，改填 http://127.0.0.1:8788 ） |
| API Key | 任意值（反代用本地配置的密钥访问学校） |
| Model ID | qwen3.8-27b |

5.4 自检

```
curl http://127.0.0.1:8788/health      # {"status": "ok", ... }
curl http://127.0.0.1:8788/v1/models  # 模型列表，供客户端自动拉取
```

5.5 注意事项

- 默认只监听 `127.0.0.1`，**外部访问不到**（安全默认值）
- 流式与非流式都已实测通过
- 反代本身不做缓存、不落盘，只是转发
- 关掉终端窗口 = 停止服务，harness 会连不上

6 模型能力与限制（决定 harness 里怎么勾）

| 能力 | 实测 | 配置建议 |
|--------|--------------|--|
| 文本对话 | <div>✔</div> | — |
| 工具调用 | <div>✔</div> | 勾选 Function Calling / Tools， 不勾 Agent 能力全废 |
| 流式 SSE | <div>✔</div> | 正常开启 |
| 视觉 | <div>✔</div> | 勾选 Vision / Images |
| 思考模式 | <div>✔</div> | 思考内容在 <code>reasoning</code> 字段（不是 <code>reasoning_content</code> ），流式在 <code>delta.reasoning</code> |
| 关闭思考 | <div>✔</div> | 请求体加 <code>chat_template_kwargs: {"enable_thinking": false}</code> ；提示词 <code>/no_think</code> 无效 |

⚠ 坑一：思考强度只有三档真实可用

`reasoning_effort` 实测结果：

| 传入 | 结果 |
|--|--|
| <code>low</code> / <code>medium</code> / <code>xhigh</code> | <div>✔ 接受</div> |
| <code>none</code> | <div>✔ 接受</div> （等于关思考） |
| <code>high</code> | <div>✖ 400</div> Supported types are xhigh (default), medium, and low. |
| <code>max</code> / <code>maximum</code> / <code>minimal</code> / <code>ultra</code> / <code>extreme</code> | <div>✖ 拒绝</div> |

界面上是「低/中/高/超高/极致」五档 → **只勾低、中、超高**，勾「高」「极致」运行时 400。（走反代可自动映射，不勾也不会报错。）

⚠ 坑二：输入 + 输出 ≤ 262144

是**总和**，不是各自独立：

| 请求 | 结果 |
|--------------------------------|------------------|
| <code>max_tokens=200000</code> | <div>✔ 接受</div> |
| <code>max_tokens=262144</code> | <div>✖ 400</div> |
| <code>max_tokens=300000</code> | <div>✖ 400</div> |

建议 harness 里填：输入 128K + 输出 32K（合计 160K 留余量）。

7

排错对照表

| 现象 | 原因 | 处理 |
|--------------------------------------|--------------------------------|--|
| 405 Method Not Allowed | Base URL 带尾斜杠，或 harness 拼了 /v1 | 去掉尾斜杠；或用反代
http://127.0.0.1:8788/v1 |
| 404 Not Found | 路径不对（如 /openai/v1/ ... ） | 检查 Base URL |
| 401 Not authenticated | 密钥错/过期/带空格 | 网页重建密钥，重新写入 api_key.txt |
| model not found | 模型名写错 | 改成 qwen3.8-27b |
| 400 Unexpected reasoning effort high | 思考强度选了「高」 | 只勾低/中/超高，或用反代自动映射 |
| 400 maximum context length is 262144 | 输入+输出超限 | 输入 128K + 输出 32K |
| 连接超时 | 当前网络到不了 202.204.64.234 | 该 IP 属教育网公网段，换网络环境或确认是否需要校园网 |
| 工具调用被当普通文本输出 | harness 没开 Function Calling | 在模型配置里勾选工具调用 |
| 思考内容混进正文 | harness 不识别 reasoning 字段 | 正常现象，多数工具会忽略或另存；反代不改写该字段 |

万能第一步：先跑自检脚本定位问题

```
check-ncepu-ai.bat
```

8

安全提醒

- ☐ **数据流向：**所有对话内容都会发往学校服务器，敏感/涉密内容**不要用**
- ☐ **密钥：**api_key.txt 是明文，别提交到 Git、别分享
- ☐ **反代：**默认只听 127.0.0.1，不要改成 0.0.0.0（那等于把学校配额开放给同网段所有人）
- ☐ **配额：**校园服务是共享资源，别跑大规模批量推理

附

相关文件

| 文件 | 用途 |
|---------------------------------------|-------------------------------|
| 网页端 202.204.64.234:8080 | 注册 / 登录 / 创建 API 密钥 / 网页对话 |
| 学校官方教程 | 原始文档 —— 注意三处勘误，见第 2 节 |
| 使用说明.md | 新手入口：3 步上手 + 文件清单 + 常见问题 |
| 接入参数.md | Qoder / WorkBuddy 详细配置 + 坑位说明 |
| ncepu_proxy.py + start-proxy.bat | 本地反代，解决 B 类 harness 的路径问题 |
| test_ncepu_ai.py + check-ncepu-ai.bat | 8 项自检脚本与双击入口 |
| api_key.txt | 密钥文件，需自行填写（第 1 行） |